Modelos “Open Weights”

Privacidad de tus datos ejecutando LLMs localmente



Bastián Carvajal Yáñez
Master en Tecnologías de la Información, fundador de Afentu

AFENTU
IA para Licitaciones Públicas

CHILETEC
Mesa de Inteligencia Artificial y Ética

Temario

¿De qué se trata este taller?

Parte 1 · ~25 min

El origen de la galaxia

· ¿Qué es un LLM? · Tokens, embeddings, parámetros · Capacidades y contexto

Interludio · ~5 min

Breve historia del Imperio

Parte 2 · ~45 min

Práctica Jedi: ejecuta LLMs localmente

· LM Studio · Ollama · ¿Qué modelo elijo?

Objetivo: que puedas responder, para tu propio caso, ¿qué modelo elijo?

Todo el material del taller, en GitHub

github.com/bastiancy/taller-open-weights-chiletec

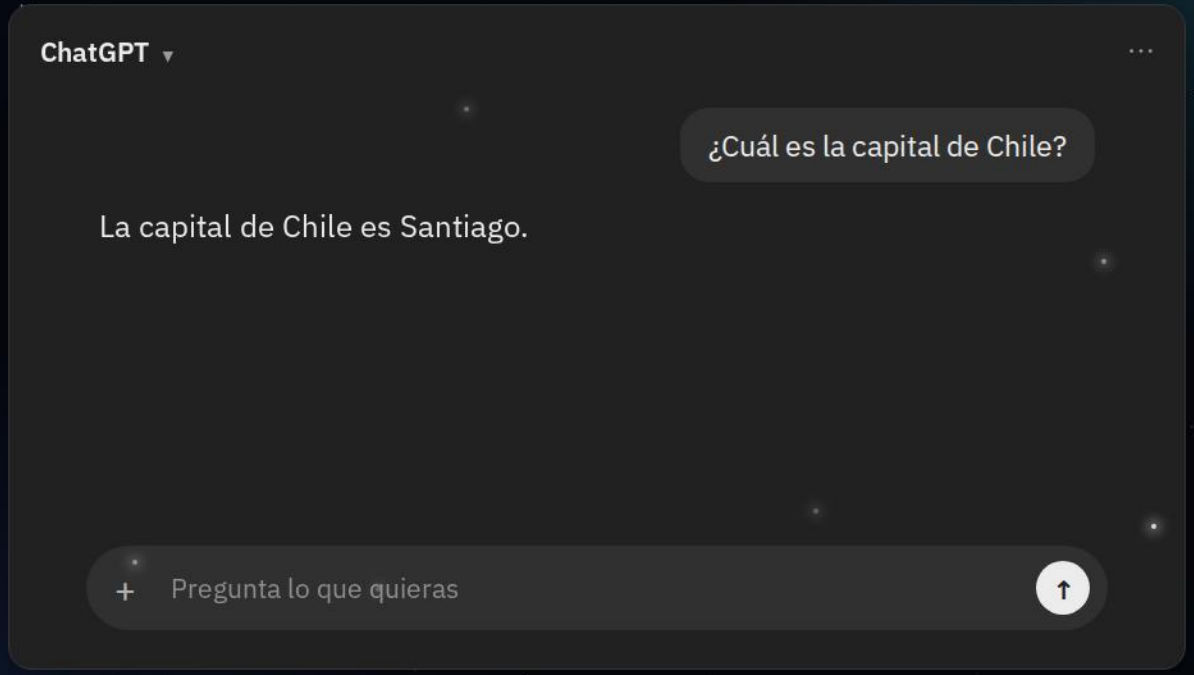
Parte 1, ~25 minutos

El origen de la galaxia

Qué hay dentro de un modelo de IA, antes de descargarlo.

El origen de la galaxia

¿Qué es un LLM? *...no, esto es un chatbot*



Es una **aplicación** de chat. Por dentro, un **LLM** recibe el texto y escribe la respuesta, token a token.

El origen de la galaxia

¿Qué es un token?



"La licitación cierra en septiembre", según el tokenizador de cada modelo

	tokens y su número (ID)	total
Llama 3.2 vocabulario de 128 mil tokens	La 8921 · lic 12553 · it 275 · ación 5840 · ci 12088 · erra 14210 · en 665 · sept 35429 · iembre 54571	9
Gemma 4 vocabulario de 262 mil tokens	La 4967 · lic 5533 · itación 65236 · cierra 215196 · en 696 · septiembre 52741	6
Qwen3 vocabulario de 152 mil tokens	La 8747 · lic 12273 · it 275 · ación 5721 · ci 11825 · erra 13886 · en 662 · sept 34329 · iembre 53471	9

Todo se mide en tokens: el **contexto**, la **velocidad** (tokens por segundo) y el **precio** de las APIs.

El origen de la galaxia

¿Qué es un embedding?

Santiago

↓

`[ 0,021 · −0,048 · 0,113 · −0,007 · … ]`

una lista de **1.024 números**

(3.072 en Llama 3.2 3B)



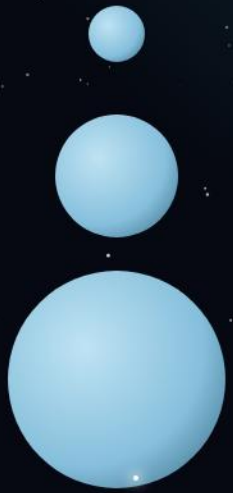
Santiago–Lima: **0,93** de similitud · Santiago–perro: **0,63**. Así busca un RAG.

El origen de la galaxia

¿Qué es un parámetro?



Cada conexión es un número aprendido: un **peso**.
Al total de pesos le llamamos **parámetros**.



3B
3.000 millones de números
~6 GB

27B
27.000 millones
~54 GB

671B
671.000 millones
~1,3 TB

Tamaño del archivo guardando cada número en 16 bits. En la práctica veremos cómo achicarlo.

El origen de la galaxia

Entonces, ¿qué es un LLM?

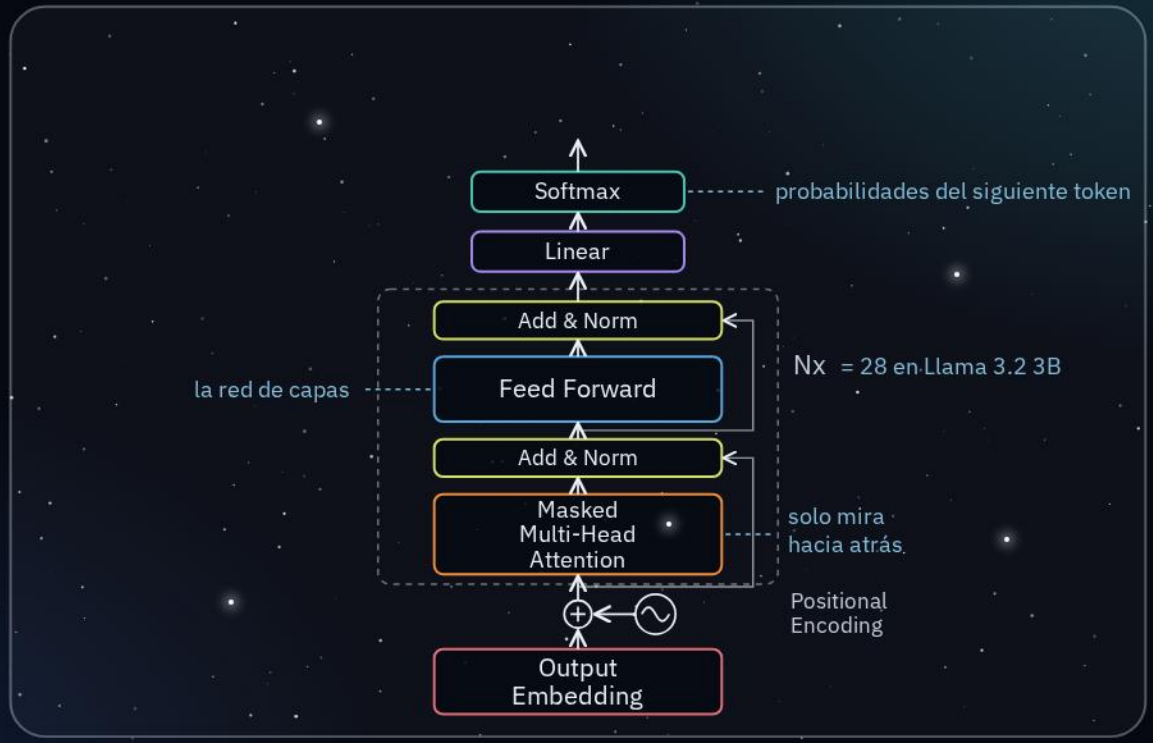
La capital de Chile es **Santiago**



Así escribe un LLM: **un token a la vez**.

El origen de la galaxia

En realidad: un Transformer



Los LLM actuales usan solo el decodificador: **decoder-only**. Llama, Qwen, Gemma, DeepSeek, gpt-oss

El origen de la galaxia

Capacidades de un modelo

Razonamiento

1.200 UF con 15% de descuento

```
pensando…
15% de 1.200 = 180
1.200 − 180 = 1.020
```

Quedan 1.020 UF.

Escribe sus pasos antes de responder: más tokens, mejores respuestas.

Uso de herramientas

¿Cuándo cierra la licitación?

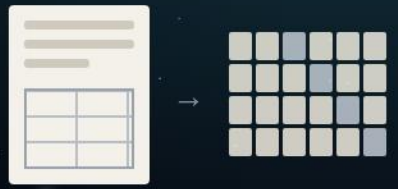
```
buscar_licitacion("2239-2-LR26")
```

⚙ tu sistema responde: **25 sep. 2026**

Cierra el 25 de septiembre.

El modelo no busca: pide que alguien busque.

Visión



La tabla tiene 3 categorías y 18 servicios.

La imagen se corta en parches y cada parche se vuelve tokens.

No todos los modelos tienen las tres. Es uno de los filtros para elegir.

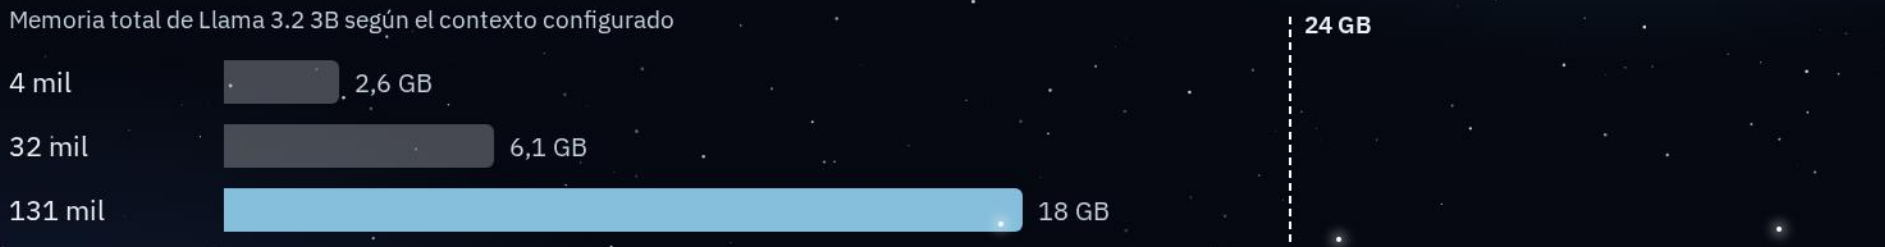
El origen de la galaxia

Ventana de contexto



Lo que el modelo ve a la vez

Llama 3.2 3B: hasta 131 mil tokens · Gemma 4 26B: hasta 262 mil



Y cada token de contexto **ocupa memoria** (la caché KV). Medido con `ollama ps` en la RTX 3090.

Interludio, ~5 minutos

Breve historia del Imperio

Una historia sobre quién controla los pesos.

Interludio: breve historia del Imperio

La rebelión Open Weights

oct. 2018 – nov. 2019
BERT y GPT-2

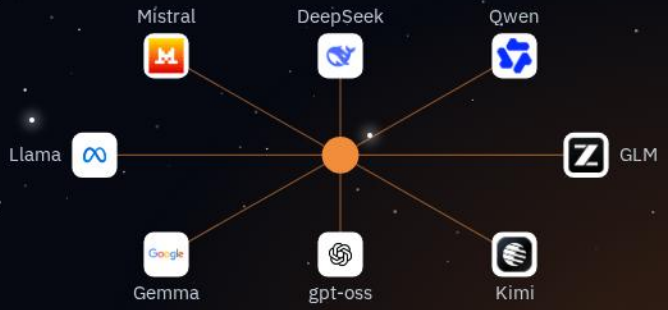
may. 2020 – nov. 2022
GPT-3 y ChatGPT

mar. 2023
LLaMA se filtra



La rebelión

Meta compartió LLaMA solo con investigadores. En una semana los pesos estaban en internet. Desde ahí, una galaxia de modelos abiertos.



Interludio: breve historia del Imperio

Tres tipos de modelo

API cerrada

No descargas nada. Tus datos viajan al servidor del proveedor.

GPT, Claude, Gemini

Open weights

Descargas el archivo de pesos y lo corres en tu equipo.

Llama, Mistral, DeepSeek, Qwen, gpt-oss

Open source

Además de los pesos, el código y los datos de entrenamiento.

OLMo

Menos control → Más control

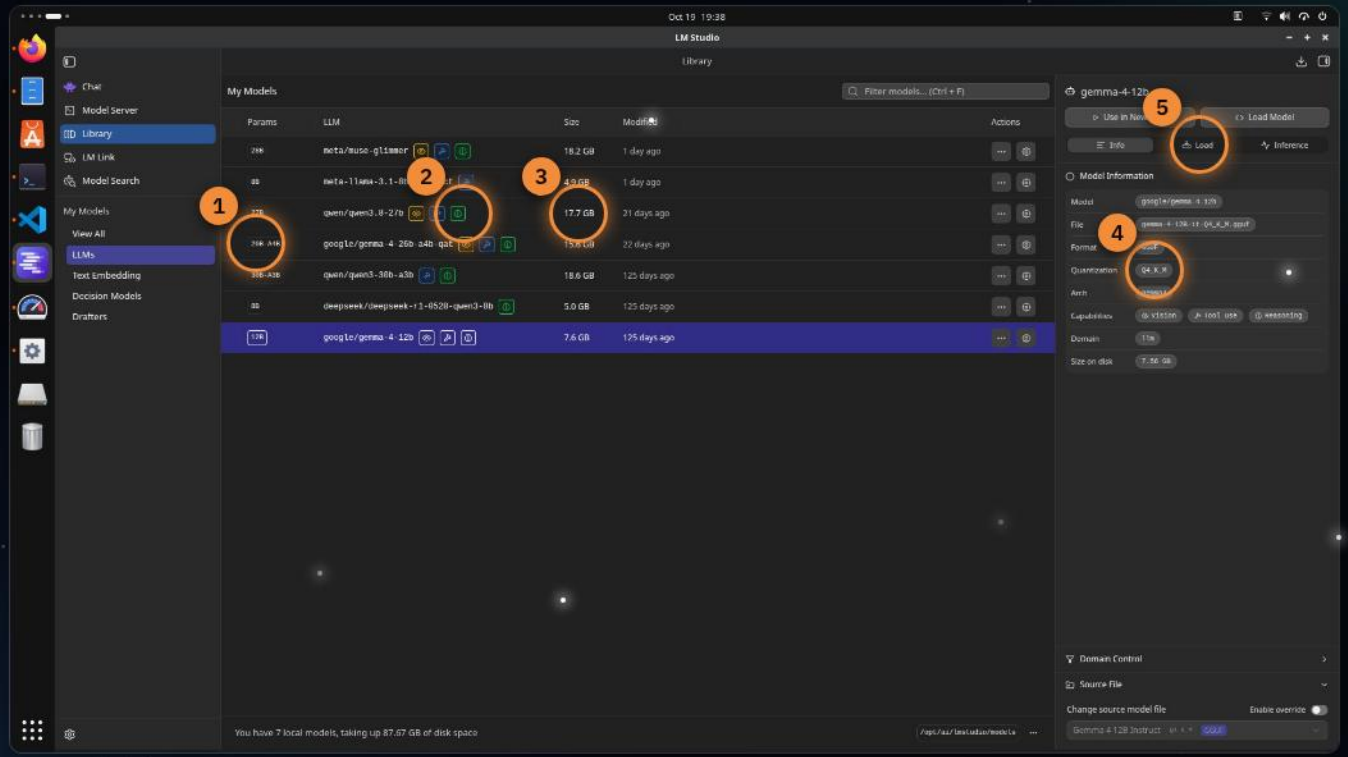
Parte 2, 60 minutos

Práctica Jedi

Los mismos conceptos, ahora en vivo.

Práctica Jedi · LM Studio

LM Studio: la biblioteca



1. **Parámetros**
   26B-A4B: 26 mil millones en total, 4 mil millones activos (MoE)
2. **Capacidades**
   visión · uso de herramientas · razonamiento
3. **Tamaño en disco**
   27B en 17,7 GB: comprimido (cuantizado)
4. **Cuantización y formato**
   Q4_K_M, archivo GGUF
5. **Pestaña Load**
   contexto y capas en GPU

Práctica Jedi · LM Studio

El nombre lo dice todo

gemma-4	26B	A4B	it	QAT	Q4_0	.gguf
familia y versión	parámetros totales	4B activos: MoE	instruct: conversa	entrenado para comprimirse	4 bits por peso	formato

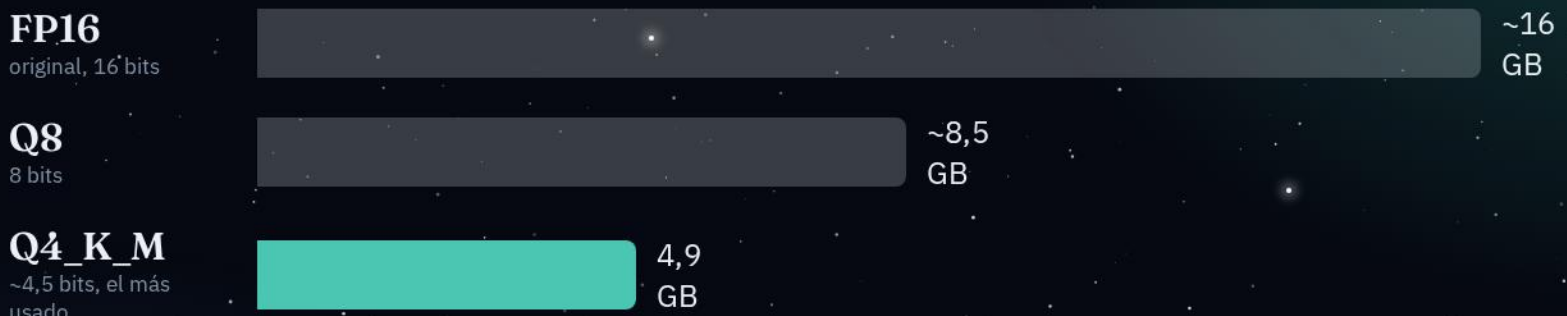
Meta-Llama-3.1	8B	Instruct	Q4_K_M
familia y versión	parámetros	post-entrenado para conversar	cuantización

DeepSeek-R1-0528	Qwen3-8B	Q4_K_M
el maestro (671B)	el alumno: destilado	cuantización

Práctica Jedi · LM Studio

Cuantizar: comprimir los pesos

Como pasar una foto de RAW a JPEG: pesa mucho menos y casi no se nota.



Llama 3.1 8B Instruct. El archivo Q4_K_M es el que está en LM Studio; FP16 y Q8 son estimaciones (bits × parámetros).

Práctica Jedi · LM Studio

Denso contra MoE

Denso: todo el modelo trabaja



MoE (mezcla de expertos): solo algunos



Solo CPU, tokens por segundo (medido en mi PC)



Ocupa memoria como uno de **26B**, pero cada token usa solo **~4B**: corre casi como uno chico.

Práctica Jedi · LM Studio

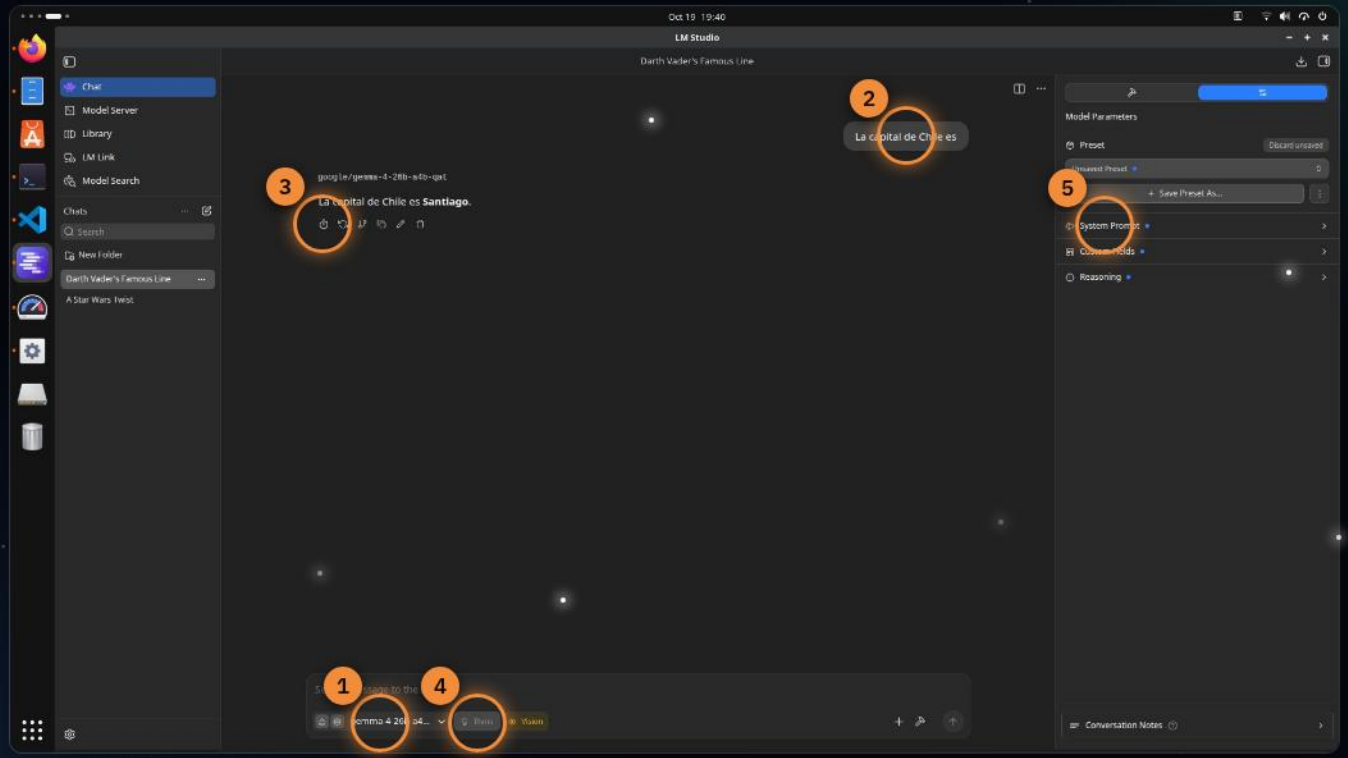
¿No cabe? Una parte va a la CPU

Los 30 bloques de Gemma 4 26B: cuántos van en la GPU y cuántos en la CPU.



Medido en una RTX 3090 con un i9-12900K. En LM Studio: pestaña Load, “GPU Offload”.

LM Studio: el chat



1. **Modelo cargado**
   gemma-4-26b-a4b-qat
2. **La misma pregunta**
   "La capital de Chile es" → Santiago
3. **Estadísticas**
   tokens por segundo y tiempo al primer token
4. **Think**
   activar o apagar el razonamiento
5. **System Prompt**
   instrucciones fijas para el modelo

Práctica Jedi · Ollama

Ollama: lo mismo, en la terminal

```
$ ollama list
gemma4:26b    17 GB
llama3.2:3b   2.0 GB
```

EN LM STUDIO
Library

```
$ ollama show gemma4:26b
parameters 25.8B · quantization Q4_K_M
context length 262144
vision · tools · thinking
```

EN LM STUDIO
Panel Info y capacidades

```
$ ollama run gemma4:26b --verbose
>>> La capital de Chile es
La capital de Chile es Santiago.  ·  eval rate: … tokens/s
```

EN LM STUDIO
Chat y estadísticas

```
$ ollama ps
gemma4:26b  17 GB  100% GPU  4096
```

EN LM STUDIO
Pestaña Load: memoria, GPU y contexto

Práctica Jedi · Ollama

Por debajo de todo: un API

```
$ curl localhost:11434/api/chat -d '{
  "model": "gemma4:26b",
  "messages": [{"role": "user",
    "content": "La capital de Chile es"}]}'
{ "message": { "role": "assistant",
    "content": "La capital de Chile es Santiago…" },
  "prompt_eval_count": 18,   ← tokens de entrada
  "eval_count": 17,   ← tokens generados
  "eval_duration": 520268000 }   ← nanosegundos
```

1. Tu aplicación, script o notebook
2. Un API local
   Ollama: localhost:11434 · LM Studio: Model Server, localhost:1234. Ambos compatibles con el API de OpenAI.
3. El modelo en formato GGUF
4. Tu GPU (o tu CPU)

Práctica Jedi

¿Qué modelo elijo?

Cuatro dimensiones, y mejorar una suele empeorar otra: más inteligencia pide más memoria, es más lenta o más cara.



Inteligencia

¿Acierta? Benchmarks y votaciones.

los 10 mejores · top 10 para mi hardware



Costo

En la nube pagas por token. En local, el equipo y la luz.

los 10 mejores · inteligencia vs costo



Velocidad

Tokens por segundo. Gemma 4 26B en mi 3090: 125 tok/s.

los 10 mejores · lo medimos en vivo



Memoria

¿Cabe en tu GPU? Parámetros × bits + contexto.

qué hardware necesito

Y además: la licencia, las capacidades (razonamiento, herramientas, visión) y, sobre todo, cómo rinde en **tu** tarea.

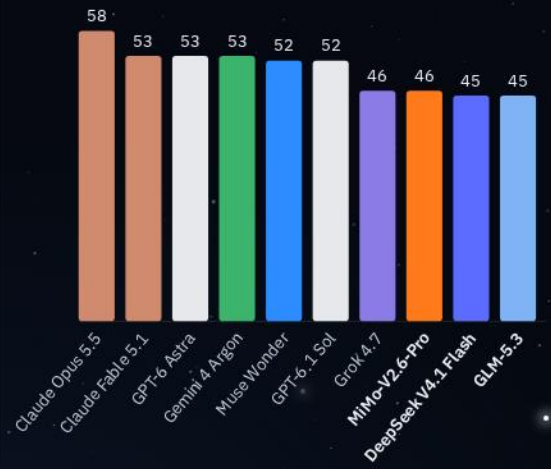
¿Qué modelo elijo? · Abiertos contra cerrados

Los más inteligentes, en tres dimensiones

Anthropic · OpenAI · Google · Meta · xAI · Xiaomi · DeepSeek · Z.ai · **negrita** = abierto

Inteligencia

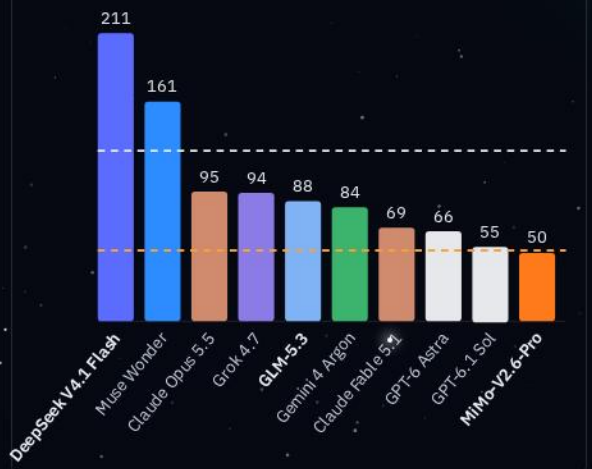
Índice de Artificial Analysis · más alto es mejor



Velocidad

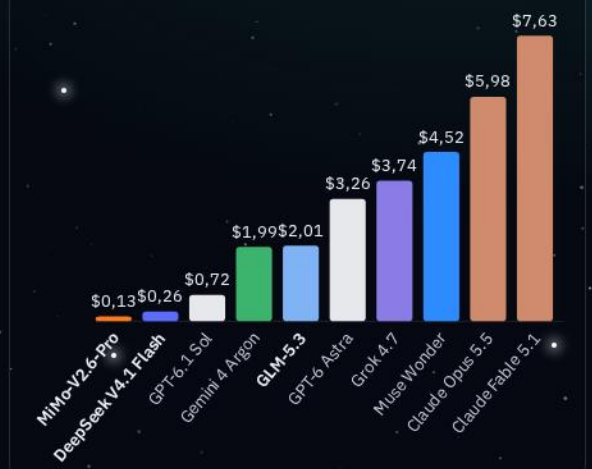
Tokens por segundo en la nube · más alto es mejor

--- en mi 3090: Gemma 4 26B 125 --- Qwen3.8 27B 52



Costo por tarea

USD por tarea del índice · más bajo es mejor



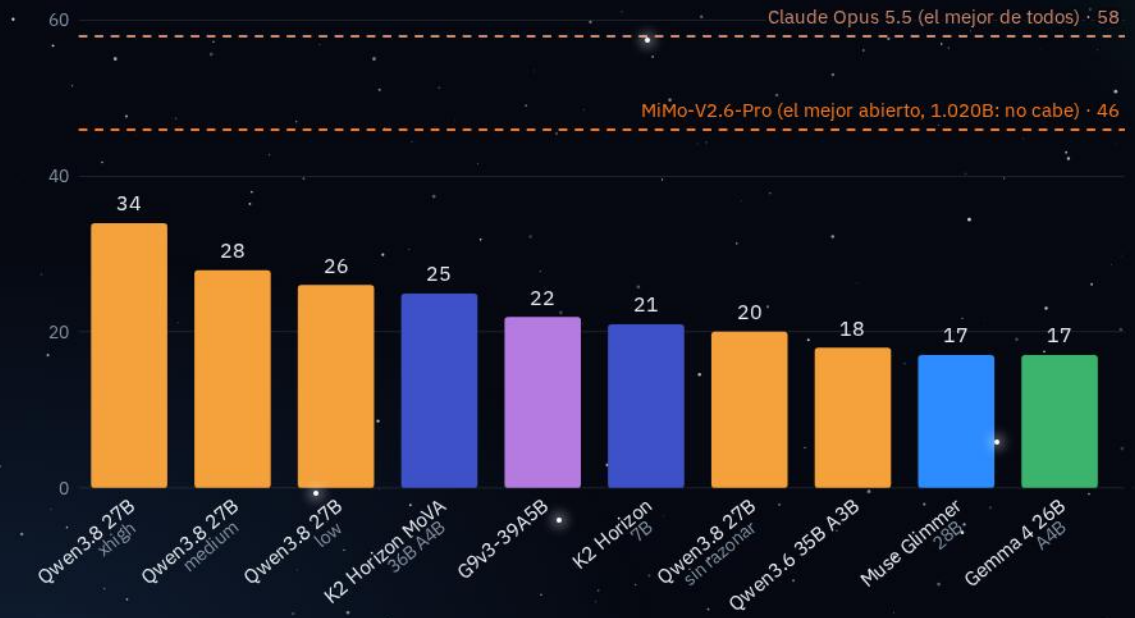
Costo: el mejor abierto es **46 veces más barato** por tarea que el más inteligente ($0,13 vs $5,98).

Fuente: artificialanalysis.ai, 20 oct. 2026 (los 10 modelos con mayor índice de inteligencia).

¿Qué modelo elijo? · Lo que corre en mi hardware

El top 10 para mi hardware

Índice de inteligencia (Artificial Analysis) · abiertos de 4B a 40B · Alibaba MBZUAI G9 Meta Google



34
Qwen3.8 27B, el mejor de su tamaño

~58
Claude Opus 5.5, el mejor de todos

139 tok/s
Gemma 4 26B en mi 3090: no es el más inteligente (17), pero es el más rápido de los que probé (Qwen3.8 27B: 52 tok/s)

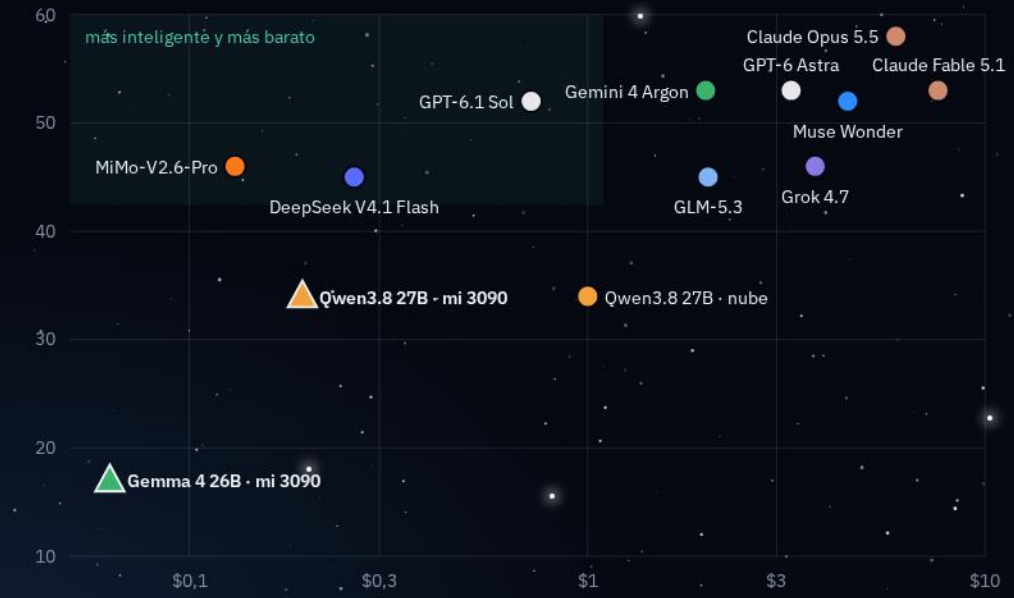
Fuente: artificialanalysis.ai, “Comparison of Small Open Source Models”, 20 oct. 2026.

¿Qué modelo elijo? · Costo

Inteligencia contra costo

Anthropic · OpenAI · Google · Meta · xAI · Xiaomi · DeepSeek · Z.ai · Alibaba · ▲ en mi 3090 (luz, estimado)

Índice de inteligencia vs costo por tarea (USD, escala log.) · ● nube ▲ mi 3090



Costo por millón de tokens generados (USD, escala log.)



Fuentes: artificialanalysis.ai, 20 oct. 2026 (10 modelos con mayor índice + Qwen3.8 27B). ▲ y luz: consumo medido en mi PC (GPU + ~100 W del resto, estimado) a ~$245/kWh, 1 USD ≈ 950 CLP; no incluye el equipo.

¿Qué modelo elijo? · Memoria

Tu memoria decide el tamaño del modelo

Equipo	Memoria para el modelo	Qué corre bien	Costo aprox. en Chile
Notebook sin GPU dedicada	RAM del sistema (16–32 GB)	Modelos pequeños o MoE, lento	$500 mil – $1,1 M
GPU de 8 GB RTX 5060	8 GB	7 a 8B en Q4	~$500 mil
GPU de 12 a 16 GB RTX 3060 · 5060 Ti	12–16 GB	12 a 14B en Q4	$420 – 900 mil
RTX 3090 usada · mi equipo	24 GB	14 a 32B en Q4	~$0,8 – 1,2 M
RTX 5090	32 GB	27B en Q6 u Q8	desde ~$3,2 M
Mac con memoria unificada MacBook Pro M5 Pro	64 GB compartidos	70B o más, más lento	~$4,4 M

Precios de la tarjeta (no el PC completo), IVA incluido, 20 oct. 2026: SoloTodo, PC Factory, Apple/retail Chile. RTX 3090 usada: Mercado Libre, referencial. GPU dedicada: más velocidad, techo fijo de memoria. Mac: más techo, menos velocidad.

Gracias

Que los teraflops de tu GPU te acompañen.

Espacio para preguntas

Material del taller

AFENTU

IA para Licitaciones Públicas

CHILETEC

Mesa de Inteligencia Artificial y Ética

Bonus · Lo que viene

¿Cuáles son los límites del modelo?

Solo sabe lo que vio al entrenarse: no conoce tus documentos, tus procesos ni tu forma de trabajar. ¿Se puede mejorar?

Sí: dándole **más datos**. Dos caminos, para casos muy distintos.

RAG

Le **muestras** la información en el momento de preguntar.

Para que sepa cosas nuevas.

Fine-tuning

Le **ajustas los pesos** con tus ejemplos.

Para que se comporte distinto.

Bonus · Lo que viene · RAG

RAG: le muestras los documentos



Sirve para

Preguntar sobre información propia o que cambia: contratos, bases, manuales, normativa. Cita la fuente.

No cambia

El modelo. Los pesos quedan iguales; si borras los documentos, olvida todo.

Bonus · Lo que viene · Fine-tuning

Fine-tuning: le ajustas los pesos



Modelo base
Los pesos que descargaste

Tus ejemplos
Cientos o miles de pares pregunta → respuesta ideal

Entrenamiento
Se ajustan los pesos (horas de GPU)

Modelo nuevo
Un archivo de pesos tuyo

Sirve para

Cambiar cómo responde: formato, tono, estilo, una tarea muy específica, un modelo chico que imite a uno grande.

No sirve para

Enseñarle datos que cambian seguido. Para eso, RAG. Muchas veces se combinan.